

MASTERARBEIT

Organisation von Bloom-Filtern zur effizienten k-nächste-Nachbarn-Suche in kontextzentrischen sozialen Netzen

Judith Greif



MASTERARBEIT

Organisation von Bloom-Filtern zur effizienten k-nächste-Nachbarn-Suche in kontextzentrischen sozialen Netzen

Judith Greif

Aufgabenstellerin: Prof. Dr. Claudia Linnhoff-Popien

Betreuer: Mirco Schönfeld
Dr. Martin Werner

Abgabetermin: 26. Juli 2016



Hiermit versichere ich, dass ich die vorliegende Masterarbeit selbständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet habe.

München, den 26. Juli 2016

.....
(*Unterschrift der Kandidatin*)

Abstract

[illegible]

Inhaltsverzeichnis

1	Einleitung	1
2	Hintergrund	3
2.1	Kontextzentrische soziale Netze	3
2.1.1	AMBIENCE	4
2.2	Bloom-Filter	4
2.2.1	Distanzmaße	5
2.2.2	Teil- und Obermengenbeziehung	6
2.2.3	Hashfunktionen	7
2.2.4	Bloom-Filter-Varianten und Anwendungen	8
2.3	Indexstrukturen	8
2.3.1	B+-Bäume	9
2.3.2	Doppelt verkettete Listen	9
3	Verwandte Themen	11
4	Implementierung	13
5	Evaluation	15
6	Zusammenfassung und Ausblick	17
	Abbildungsverzeichnis	19
	Literaturverzeichnis	21

1 Einleitung

Die digitale Kommunikation hat im letzten Jahrzehnt einen rapiden Wandel erlebt. Soziale Online-Netzwerke¹ haben an Bedeutung gewonnen und zu neuen Kommunikationsmustern im Internet geführt. Sofortnachrichtendienste und Instant-Messenger ersetzen zunehmend Kommunikationsformen wie SMS und Telefonie. Das Smartphone hat das Mobiltelefon als mobiles Endgerät fast vollständig abgelöst. Feststehende Desktop-Rechner mit einem gleich bleibenden Netzzugang sind außerhalb von Firmen und Bildungseinrichtungen rückläufig. Dagegen sind Notebooks und Tablets weiterhin auf Erfolgsweg².

Die Kommunikation im Internet ist jedoch nach wie vor Ende-zu-Ende- beziehungsweise adressbasiert. Das spiegelt sich im Aufbau der bestehenden sozialen Online-Netzwerke wider: Kommunikation basiert darin auf Online-Freundschaft. Mobilität und spezifischer Kontext der Mitglieder werden kaum berücksichtigt. In der Realität verlieren die Webbrowser-Schnittstellen der sozialen Netzwerke jedoch an Bedeutung. So veröffentlichte Facebook 2014 eine Studie zum Nutzerverhalten von US-Bürgern in einer Multigeräte-Welt³. Danach nutzten 60% der Erwachsenen in den USA täglich mindestens zwei Endgeräte, knapp 25% sogar drei Geräte. Mehr als 40% begannen den Tag mit einem Gerät und beendeten ihn mit einem anderen. Das Smartphone ist dabei das Gerät, das am häufigsten mitgenommen wird und eine zentrale Rolle in der Kommunikation per E-Mail und in sozialen Netzen einnimmt. Das Szenario, in dem Alice vor ihrem Desktop-Rechner zu Hause oder im Büro sitzt und über die Webbrowser-Schnittstelle Nachrichten an ihren Facebook-Freund Bob schreibt, gehört demnach der Vergangenheit an. Stattdessen verwendet Alice wohl eher ein Tablet, ein Notebook und ein Smartphone und kommuniziert mit Bob je nach Aufenthaltsort und Kontext ganz unterschiedlich.

So stellt sich die Frage nach einer Neuorientierung der sozialen Online-Netze: Nicht nur in der praktischen Umsetzung, also durch Schaffung unterschiedlicher Schnittstellen und neuer Funktionalitäten, sondern im Sinne eines tatsächlichen Paradigmenwechsels. Ein kontextzentrisches soziales Netz basiert in seiner Struktur nicht auf Ende-zu-Ende-Kommunikation, adressbasiertem Routing und einem gleich bleibenden Netzzugang. Kommunikation beruht allein auf Kontext-Ähnlichkeit statt auf virtueller Freundschaft. Diese Überlegungen sind z.B. in das soziale Online-Netz AMBIENCE eingeflossen. Nachrichten werden darin auf Grund von zeitlicher und räumlicher Ähnlichkeit ausgetauscht, Sender und Empfänger bleiben weitgehend anonym. Ein solches Netz erfordert eine neue Kommunikationsstruktur. Nachrichten werden nicht aktiv von einem Sender für einen spezifischen Empfänger verfasst und an ihn verschickt. Stattdessen kann ein Sender eine Nachricht verfassen und z.B. an einem WiFi-Access Point hinterlegen. Mitglieder des Netzwerks, die sich in der Nähe des Access Points aufhalten, können die dort vorhan-

¹Der englische Begriff hierfür lautet *Online Social Network (OSN)*. Die Begriffe *Soziales Netz*, *Soziales Online-Netz* und *Soziales Online-Netzwerk* werden im Folgenden synonym verwendet.

²Laut Analysen der Marktforschungsinstitute Gartner und IDC, vgl. z.B. <http://www.golem.de/news/pc-markt-absatz-von-pcs-geht-weiter-erheblich-zurueck-1601-118505.html>.

³Vgl. <https://www.facebook.com/business/news/Finding-simplicity-in-a-multi-device-world>.

denen Nachrichten mit gezielten Anfragen durchsuchen und die zum jeweiligen Kontext ähnlichsten Nachrichten abrufen.

Damit stellt sich die Frage: Wie lassen sich die Nachrichten an einem Host, also z.B. an einem WiFi-Access Point, so organisieren, dass die k ähnlichsten Nachrichten möglichst schnell und effizient gefunden werden? Wenn das soziale Netz wachsen und über den Status eines Prototypen hinaus erfolgreich sein soll, ist das von entscheidender Bedeutung. Mengentheoretisch betrachtet handelt es sich dabei um das Problem der k -nächsten-Nachbarn-Suche, die zu einer Anfrage die k ähnlichsten Elemente einer Menge, hier bestehend aus den Nachrichten an einem Host, finden soll.

Damit verknüpft ist die Frage nach der Nachrichtenform. Wie können Multimedia-Nachrichten wie Bilder, Textdateien oder Links effizient, einheitlich und sicher vor unbefugtem Zugriff hinterlegt und verschickt werden? Zudem muss die Ähnlichkeit oder Unähnlichkeit von Nachrichten ermittelt werden können, d.h. der k -nächste-Nachbarn-Suche muss ein Ähnlichkeitsmaß zu Grunde liegen. AMBIENCE verwendet dazu eine Bloom-Filter-Konstruktion. Eine Nachricht wird als Menge von Zeichenketten aufgefasst, die mit geeigneten Hashfunktionen in ein Bit-Array fester Länge eingefügt werden. Ähnlichkeit zwischen Nachrichten ist damit als Ähnlichkeit zwischen Bloom-Filtern definiert. Nachrichten werden in Form von Bloom-Filtern kodiert, gespeichert und verglichen. Als Ähnlichkeitsmaß dient die Jaccard-Distanz, mit der sich die Ähnlichkeit von Mengen beschreiben lässt.

Die folgende Arbeit behandelt daher die Organisation von Bloom-Filtern zur effizienten k -nächste-Nachbarn-Suche in kontextzentrischen sozialen Netzen. Das folgende Kapitel 2 gibt einen Überblick über mengentheoretische und probabilistische Grundlagen, verwendete Datenstrukturen und ihre Nutzung in AMBIENCE. Kapitel 3 gibt einen Überblick über verwandte Arbeiten und Fragestellungen. Das entwickelte Verfahren wird anschließend in Kapitel 4 dargestellt. Kapitel 5 vergleicht die Implementierung mit dem bisherigen, nicht optimierten Ansatz. Im abschließenden Kapitel 6 wird ein Fazit gezogen und auf mögliche zukünftige Arbeiten eingegangen.

2 Hintergrund

Im Folgenden wird das Konzept des *kontextzentrischen sozialen Netzes* erläutert, das dieser Arbeit zu Grunde liegt. Anschließend werden mengentheoretische und probabilistische Grundlagen und Verfahren sowie Daten- und Indexstrukturen dargestellt, die Eingang in diese Arbeit gefunden haben. Es wird erläutert, inwiefern sie für das soziale Online-Netz AMBIENCE relevant sind oder darin verwendet werden.

2.1 Kontextzentrische soziale Netze

Wie eingangs dargestellt lässt sich mit Zunahme der mobilen Endgeräte und dem Erfolg des Smartphones eine Tendenz beobachten, die in bestehenden sozialen Online-Netzwerken wenig abgebildet wird: Weg von adressbasiertem Routing und Ende-zu-Ende-Kommunikation hin zu *context-awareness* und *information-centric networking*.

Der Begriff context-awareness wurde von Schilit et al. 1994 geprägt und bezeichnet die Nutzung von Kontextinformationen als Informationsquelle für Anwendungen und Netzwerke¹. Information-centric networking (ICN) bezeichnet ein neuartiges Konzept für Netzwerke, die nicht auf Ende-zu-Ende- oder Sender/Empfänger-Kommunikation basieren, sondern auf den im Netzwerk vorhandenen Informationen². Der Begriff *Kontext* im Zusammenhang mit interaktiven Anwendungen wurde bereits in den 90er Jahren geprägt. In der klassischen Definition von Dey und Abowd bedeutet Kontext

[...] any information that can be used to characterize the situation of an entity. An entity is a person, place, or object that is considered relevant to the interaction between a user and an application including the user and application themselves³.

Diese Definition wird für soziale Online-Netze eingegrenzt:

Context is any information that can be used to infer aspects of the surroundings of an entity in a way, in which some applications may have interest. Surroundings include all information that could possibly impact the behaviour of the entity⁴.

Ein kontextzentrisches soziales Netz ist also ein soziales Online-Netz, das auf Kontext-Variablen wie Ort und Zeit als Informationsquellen basiert und in der Regel dezentral organisiert ist (z.B. mit einer Peer-to-Peer- statt einer Client/Server-Architektur). Kommunikation beruht darin allein auf Kontext-Ähnlichkeit, nicht auf Online-Freundschaft:

¹Vgl. [SAW94].

²Vgl. [ADI⁺12] für eine ausführliche Darstellung.

³[DA99]: 306f..

⁴[WDS15]: 2.

A context-centric online social network is an online social network in which the edges of the social graph are defined from context information and context matching algorithms. An edge between two profiles exists for a fixed information object if and only if the two profiles share the relevant context as defined by the publisher⁵.

2.1.1 AMBIENCE

AMBIENCE ist ein soziales Online-Netzwerk, das 2015 als Prototyp implementiert wurde und sich an diesem neuen Paradigma orientiert. Die vorliegende Arbeit hat das Ziel, einen spezifischen Aspekt des Netzwerks zu optimieren, nämlich die Organisation der Nachrichten an einem Host für k -nächste-Nachbarn-Anfragen. Nachrichten und Anfragen werden in AMBIENCE als Bloom-Filter kodiert. Bei einer Anfrage wird also ein Anfrage-Filter mit einer Menge von Bloom-Filtern verglichen, die an einem Host gespeichert sind. Aktuell werden die Filter dort einfach als unsortierte Liste gespeichert. Die Laufzeit für k -nächste-Nachbarn-Anfragen an einen Host mit n Filtern liegt damit in $O(n^2)$. Dieses Laufzeitverhalten gilt es zu optimieren, wenn das Netzwerk wachsen und über den Status eines Prototypen hinaus erfolgreich sein soll.

2.2 Bloom-Filter

Ein Bloom-Filter ist eine probabilistische Datenstruktur zur Beschreibung von Mengen, die in der ursprünglichen Form 1970 von Burton H. Bloom eingeführt wurde⁶. Er besteht aus einem Bit-Array der festen Länge m , dessen Elemente zunächst alle auf 0 gesetzt sind. Das Einfügen von Informationsobjekten basiert auf der Berechnung einer festen Anzahl k unabhängiger Hashfunktionen, die positive Werte kleiner als m annehmen. Soll ein Objekt in den Filter eingefügt werden, werden seine Hashwerte berechnet und die entsprechenden Bits im Filter gesetzt⁷.

Die Hashwerte werden verwendet, um Anfragen auf dem Filter auszuführen. Ist ein Objekt im Filter enthalten, sind seine Bits gesetzt worden, d.h. man kann eine Anfrage nach seinen Hashwerten durchführen und so mit großer Wahrscheinlichkeit ermitteln, ob es in den Filter eingefügt wurde: Sind ein oder mehrere Bits des Anfrageobjekts nicht gesetzt, so ist das Element mit Sicherheit nicht vorhanden. Es gibt also keine falsch negativen Antworten. Allerdings kann es sein, dass ein Element nicht in den Filter eingefügt wurde, obwohl alle seine Bits gesetzt sind (falsch positive Antworten). Grund dafür ist die Kollisionseigenschaft von Hashfunktionen, die ein großes Universum von Elementen auf einen sehr viel kleineren Wertebereich, hier die Länge des Bloom-Filters, abbilden. Es kann somit zu Kollisionen zwischen unterschiedlichen Informationsobjekten bzw. ihren charakteristischen Hashwerten kommen. Die Falsch-Positiv-Rate eines Bloom-Filters ist abhängig von m , k und der Anzahl der eingefügten Elemente n und lässt sich berechnen als⁸

$$f = \left(1 - \left(1 - \frac{1}{m}\right)^{kn}\right)^k.$$

⁵[WDS15]: 4.

⁶Vgl. [Blo70].

⁷Vgl. [BM04]: 487.

⁸Vgl. ebd. für eine umfassende Darstellung.

Aus der Kollisionseigenschaft folgt auch, dass ein einmal eingefügtes Objekt nicht mehr aus einem Bloom-Filter gelöscht werden kann, weil das offensichtlich zu falsch negativen Ergebnissen für andere Objekte führen könnte.




Abbildung 2.1: Beispiel für einen Bloomfilter, in den die Objekte x , y und z eingefügt wurden. Das Objekt w ist nicht im Filter vorhanden.

2.2.1 Distanzmaße

Um die Ähnlichkeit zweier Mengen zu ermitteln, werden verschiedene Distanzmetriken oder Ähnlichkeitsmaße eingesetzt. Um Bloom-Filter miteinander zu vergleichen und insbesondere für die k -nächste-Nachbarn-Suche muss ein geeignetes Ähnlichkeitsmaß zur Anwendung kommen. Bayardo et al. verwenden dazu die *Kosinus-Ähnlichkeit*⁹. Sakuma und Sato definieren die Ähnlichkeit von Bloom-Filtern über die Anzahl gleicher 1-Bits¹⁰. Ist diese für zwei Anfragefilter identisch, werden die Bit-Arrays negiert und die Anzahl gleicher 0-Bits verglichen.

AMBIENCE verwendet eine Abschätzung der *Jaccard-Distanz* zur Ermittlung der Ähnlichkeit von Bloom-Filtern. Die Jaccard-Distanz zwischen zwei Mengen A und B ist definiert als

$$J_\delta(A, B) = 1 - J(A, B) = \frac{|A \cap B| - |A \cup B|}{|A \cup B|},$$

wobei

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

den *Jaccard-Koeffizienten* bezeichnet. Die Jaccard-Distanz nimmt Werte im Bereich $[0, 1]$ an. Identische Mengen haben eine Jaccard-Distanz von 0, Mengen ohne gemeinsame Elemente haben eine Jaccard-Distanz von 1. Für Bloom-Filter lässt sich die Jaccard-Distanz analog berechnen. Die Vereinigungsmenge zweier Bloom-Filter F und G lässt sich als bitweises logisches Oder, die Schnittmenge als bitweises logisches Und repräsentieren. Auch hier nimmt die Jaccard-Distanz offensichtlich Werte zwischen 0 und 1 an. Je ähnlicher die Filter sind, desto kleiner ist ihre Jaccard-Distanz. Die Jaccard-Distanz zwischen Bloom-Filtern ist, anders als die von Sakuma und Sato verwendete Distanz-Metrik, nicht transitiv in dem Sinne, dass zwei Filter, die beide eine geringe Jaccard-Distanz zu einem dritten Filter aufweisen, untereinander nicht ähnlich sein müssen. Man betrachte z.B. die

⁹Vgl. [BMS07].

¹⁰Vgl. [SS11]: 321.

2 Hintergrund

Filter $F1$, $F2$ und $F3$ mit folgenden Werten: Die Jaccard-Distanzen zwischen $F1$, $F2$ und $F3$ betragen somit:

$$J_\delta(F1, F3) = 1 - J(F1, F3) = 1 - \frac{|F1 \cap F3|}{|F1 \cup F3|} = 1 - \frac{5}{10} = 0.5$$

$$J_\delta(F2, F3) = 1 - J(F2, F3) = 1 - \frac{|F2 \cap F3|}{|F2 \cup F3|} = 1 - \frac{5}{10} = 0.5$$

$$J_\delta(F1, F2) = 1 - J(F1, F2) = 1 - \frac{|F1 \cap F2|}{|F1 \cup F2|} = 1 - 0 = 1$$

Daran wird deutlich: Obwohl $F1$ und $F2$ jeweils die Hälfte der Elemente mit $F3$ gemeinsam haben, lässt sich daraus kein Wert für die Ähnlichkeit zwischen $F1$ und $F2$ ableiten. Sie sind sich im Gegenteil maximal unähnlich.

2.2.2 Teil- und Obermengenbeziehung

Will man Bloom-Filter z.B. nach Ähnlichkeit gruppieren, kann man stattdessen Teil- und Obermengenbeziehungen zwischen ihnen betrachten. Die Teilmengenbeziehung zwischen zwei Bloom-Filtern sei hier wie folgt definiert:

Ein Bloom-Filter F ist **Teilmenge** eines Bloom-Filters G , wenn darin mindestens die gleichen 0-Bits gesetzt sind wie in G (und möglicherweise weitere, zusätzliche 0-Bits).

Die Obermengenbeziehung zwischen zwei Bloom-Filtern sei hier wie folgt definiert:

Ein Bloom-Filter F ist **Obermenge** eines Bloom-Filters G , wenn darin mindestens die gleichen 1-Bits gesetzt sind wie in G (und möglicherweise weitere, zusätzliche 1-Bits).

Der maximal gefüllte Filter, in dem alle Bits gesetzt sind, ist damit Obermenge aller Filter derselben Länge (auch von sich selbst). Der leere Filter ist die (triviale) Teilmenge aller Filter derselben Länge (auch von sich selbst). Teil- und Obermengen sind Umkehrungen

F1	1	1	1	1	1	0	0	0	0	0
F2	0	0	0	0	0	1	1	1	1	1
F3	1	1	1	1	1	1	1	1	1	1

Abbildung 2.2: Jaccard-Distanzen zwischen Bloom-Filtern.

voneinander, d.h. wenn F Teilmenge von G ist, folgt daraus, dass G Obermenge von F ist, und umgekehrt.

Zwischen den Bloom-Filtern in Abb. 2.2 bestehen folgende Teil- und Obermengenbeziehungen: $F1$ und $F2$ sind Teilmengen von $F3$. $F3$ ist Obermenge von $F1$ und $F2$. Zwischen den maximal unähnlichen Filtern $F1$ und $F2$ bestehen keine Teil- und Obermengenbeziehungen.




Abbildung 2.3: Teil- und Obermengenbeziehungen zwischen Bloom-Filtern.

Teil- und Obermengenbeziehung sind außerdem transitiv, was an Abb. 2.3 deutlich wird: $F1$ ist Teilmenge von $F2$, damit auch Teilmenge von $F3$. $F3$ ist Obermenge von $F2$, damit auch Obermenge von $F1$.

Teil- und Obermengenbeziehungen sind also im Gegensatz zur Jaccard-Distanz dazu geeignet, transitive Ähnlichkeitsbeziehungen zwischen Bloom-Filtern abzubilden. Diese Eigenschaft spielt eine zentrale Rolle im hier entwickelten Verfahren, das in Kap. 4 ausführlich dargestellt wird.

2.2.3 Hashfunktionen

Die Frage nach den idealen Hashfunktionen für einen Bloom-Filter ist nicht eindeutig zu beantworten¹¹. Grundsätzlich muss zwischen kryptografischen Hashfunktionen wie MD5 und SHA und gewöhnlichen Hashfunktionen wie Murmur- oder Jenkins-Hashfunktionen unterschieden werden. Die Berechnung von kryptografischen Hashfunktionen dauert in der Regel länger, dafür haben sie bestimmte Eigenschaften wie eine hohe Kollisionsresistenz und Gleichverteilung der Ergebniswerte.

Werden Bloom-Filter z.B. zum schnellen Nachschlagen in großen, verteilten Datenbanken eingesetzt, wird auf die kryptografischen Eigenschaften zu Gunsten des verminderten Rechenaufwandes verzichtet. Das NoSQL-Datenbanksystem Cassandra und das Hadoop-Framework für skalierte, verteilt arbeitende Software verwenden beispielsweise Bloom-Filter in Kombination mit Murmur- und Jenkins-Hashfunktionen. Darüber hinaus ist MD5 für Bloom-Filter weit verbreitet. Die Murmur-Hashfunktionen weisen gleichzeitig gute Verteilungseigenschaften auf und lassen sich vergleichsweise schnell berechnen, wes-

¹¹Vgl. [BM04]: 487.

wegen sie generell für den Einsatz in Bloom-Filtern empfohlen werden¹². AMBIENCE verwendet Murmur-Hashfunktionen zur Generierung der Bloom-Filter. Für die eigene Implementierung wurde der Murmur2-Hash verwendet¹³.

2.2.4 Bloom-Filter-Varianten und Anwendungen

Wegen ihres geringen Speicherbedarfs und einfachen Implementierung erfreuen sich Bloom-Filter in unterschiedlichsten Versionen großer Beliebtheit. Wichtige Varianten sind z.B. *Attenuated Bloom Filter*, *Counting Bloom-Filter* und *Compressed Bloom Filter*. Ein Counting Bloom-Filter benötigt mehr Speicherplatz als ein klassischer Bloom-Filter, dafür können Objekte wieder daraus entfernt werden¹⁴. Komprimierte Bloom-Filter werden eingesetzt, wenn Bloom-Filter als Nachrichten mit begrenzter Länge versendet werden oder die übertragene Datenmenge minimiert werden soll¹⁵. Attenuated Bloom-Filter¹⁶ können als Array von Bloom-Filtern betrachtet werden und können z.B. in einem Netzwerk Informationen darüber enthalten, welche Dienste an einem anderen Knoten verfügbar sind. Besonders häufig kommen Bloom-Filter in verteilten Anwendungen und Netzwerkdiensten zum Einsatz¹⁷.

Neben Hadoop und Cassandra werden Bloom-Filter in unzähligen, zum Teil hoch skalierenden Anwendungen eingesetzt. Weitere Beispiele sind der quelloffene Webproxy Squid und der Chrome-Browser, wo Bloom-Filter zum schnellen Nachschlagen als böseartig eingestufte Webseiten verwendet werden. Broder und Mitzenmacher formulieren das Bloom-Filter-Prinzip wie folgt:

Wherever a list or set is used, and space is at a premium, consider using a Bloom filter if the effect of false positives can be mitigated¹⁸.

2.3 Indexstrukturen

Zur effizienten Bearbeitung von Anfragen und Operationen kommen in der internen Schicht von Datenbanksystemen spezielle Datenstrukturen und Speicherverfahren zum Einsatz. Sie werden *Indexstrukturen* genannt und organisieren die Daten an Hand von Indizes, um die gewünschten Operationen zu unterstützen¹⁹.

Ein *Index* oder *Verzeichnis* einer Datei enthält Informationen über ihre Struktur, wobei mit „Datei“ in diesem Zusammenhang eine komplette Datenstruktur gemeint ist, also z.B. ein Suchbaum oder ein Array. Indexstrukturen lassen sich danach klassifizieren, wie sie die Daten organisieren:

¹²Vgl. <http://spyced.blogspot.de/2009/01/all-you-ever-wanted-to-know-about.html>.

¹³Vgl. <https://sites.google.com/site/murmurhash/MurmurHash2.cpp> für den Quellcode.

¹⁴Vgl. [FCAB00].

¹⁵Vgl. [Mit02].

¹⁶Vgl. [SS11]: 316 und 318.

¹⁷Vgl. [BM04] für eine ausführliche Darstellung.

¹⁸[BM04]: 486.

¹⁹Trotz der großen Verbreitung von Indexstrukturen in Datenbanksystemen scheinen in der Literatur keine überblicksartigen Darstellungen zu existieren. Der aktuelle Abschnitt stützt sich daher im Wesentlichen auf das Skript zur Vorlesung *Anfragebearbeitung und Indexstrukturen in Datenbanksystemen* im Wintersemester 2013/2014 an der Ludwig-Maximilians-Universität München (vgl. [Kri14]).

1. *Daten-organisierende Indexstrukturen* werden zur Organisation der tatsächlich anfallenden Daten eingesetzt – meist in Form von *Suchbäumen*.
2. *Raum-organisierende Indexstrukturen* werden zur Organisation des Speichers eingesetzt, in dem die Daten gehalten werden. Sie verwenden vor allem *dynamische Hashverfahren*.
3. *Hybride Indexstrukturen* sind eine Kombination der vorgenannten Klassen und basieren auf *Hashbäumen*.

Anforderungen an eine gute oder effektive Indexstruktur können sein:

- *Effiziente Suche*: Eine Suchanfrage auf der Indexstruktur soll in optimaler Zeit ein Ergebnis liefern. D.h. die Anfrage soll in möglichst wenig Schritten an die Seite oder Seiten weiter geleitet werden, die die angefragten Daten enthält oder enthalten.
- *Dynamisches Einfügen, Modifizieren und Löschen von Datensätzen*: Die zu organisierende Datenmenge verändert sich möglicherweise über die Zeit, was durch die Indexstruktur widerspiegelt und unterstützt werden muss.
- *Erhalt der lokalen Ordnung*: Falls es Datensätze gibt, deren Schlüssel in der angewandten Ordnungsrelation (z.B. die Kleiner-Gleich-Ordnung) aufeinander folgen, sollte die Indexstruktur das widerspiegeln. Diese Eigenschaft wird von Suchbäumen erfüllt, nicht aber von linearen Hashverfahren. Die Wahl bzw. Implementierung der Indexstruktur muss also nach dem jeweiligen Anwendungsfall erfolgen.
- *Speichereffizienz*: Effiziente Speichernutzung ist vor allem in der realen Welt und in hoch skalierenden Anwendungen von zentraler Bedeutung.

Weitere Anforderungen beinhalten *Machbarkeit* und *Implementierungskosten*. Für die hier vorgestellte Implementierung wird darauf nicht näher eingegangen. [OW12]

2.3.1 B+-Bäume

[Knu98]

2.3.2 Doppelt verkettete Listen

3 Verwandte Themen

[AT06], [BCM02], [DWM10], [HP94], [LC86], [Naf05], [QLC14], [RK14], [SBE⁺12], [Sch13], [SW14], [STT⁺09], [YL02], [Zha12], [ZJW04], [Jan95].

4 Implementierung

5 Evaluation

6 Zusammenfassung und Ausblick

Abbildungsverzeichnis

2.1	Bloomfilter-Beispiel, Bildnachweis: https://commons.wikimedia.org/wiki/File:Bloom_filter.svg	5
2.2	Jaccard-Distanzen zwischen Bloom-Filtern	6
2.3	Teil- und Obermengenbeziehungen zwischen Bloom-Filtern	7

Literaturverzeichnis

- [ADI⁺12] AHLGREN, BENGT, CHRISTIAN DANNEWITZ, CLAUDIO IMBRENDA, DIRK KUTSCHER und BÖRJE OHLMAN: *A Survey of Information-Centric Networking*. Communications Magazine, IEEE, 50(7):26–36, 2012.
- [AT06] AGARWAL, SACHIN und ARI TRACHTENBERG: *Approximating the number of differences between remote sets*. In: *Information Theory Workshop, 2006. ITW '06 Punta del Este. IEEE*, Seiten 217–221, March 2006.
- [BCM02] BYERS, JOHN, JEFFREY CONSIDINE und MICHAEL MITZENMACHER: *Fast Approximate Reconciliation of Set Differences*. In: *BU Computer Science TR*, Seiten 2002–2019, 2002.
- [Blo70] BLOOM, BURTON: *Space/Time Trade-offs in Hash Coding with Allowable Errors*. Communications of the ACM, 13(7):422–426, 1970.
- [BM04] BRODER, ANDREI und MICHAEL MITZENMACHER: *Network Applications of Bloom Filters: A Survey*. Internet Mathematics, 1(4):485–509, 2004.
- [BMS07] BAYARDO, ROBERTO, YIMING MA und RAMAKRISHNAN SRIKANT: *Scaling Up All Pairs Similarity Search*. In: *Proceedings of the 16th international conference on World Wide Web*, Seiten 131–140. ACM, 2007.
- [DA99] DEY, ANIND und GREGORY ABOWD: *Towards a Better Understanding of Context and Context-Awareness*. In: *Handheld and Ubiquitous Computing*, Seiten 304–307. Springer, 1999.
- [DWM10] DÜRR, MICHAEL, MARTIN WERNER und MARCO MAIER: *Re-Socializing Online Social Networks*. In: *Green Computing and Communications (GreenCom), 2010 IEEE/ACM International Conference on & International Conference on Cyber, Physical and Social Computing (CPSCoM)*, Seiten 786–791. IEEE, 2010.
- [FCAB00] FAN, LI, PEI CAO, JUSSARA ALMEIDA und ANDREI BRODER: *Summary Cache: A Scalable Wide-Area Web Cache Sharing Protocol*. IEEE/ACM Transactions on Networking (TON), 8(3):281–293, 2000.
- [HP94] HELLERSTEIN, JOSEPH und AVI PFEFFER: *The RD-Tree: An Index Structure for Sets*. Technischer Bericht, University of Wisconsin-Madison, Computer Sciences Department, 1994.
- [Jan95] JANNINK, JAN: *Implementing Deletion in B+-Trees*. ACM Sigmod Record, 24(1):33–38, 1995.
- [Knu98] KNUTH, DONALD: *The art of computer programming, Volume 3, Sorting and searching*. Addison Wesley Longman, 1998.
- [Kri14] KRIEGEL, HANS-PETER: *Skript zur Vorlesung Anfragebearbeitung und Indexstrukturen in Datenbanksystemen*. 1994–2014.

- [LC86] LEHMAN, TOBIN und MICHAEL CAREY: *A Study of Index Structures for Main Memory Database Management Systems*. In: *Proc. VLDB*, 1986.
- [Mit02] MITZENMACHER, MICHAEL: *Compressed Bloom Filters*. *IEEE/ACM Transactions on Networking (TON)*, 10(5):604–612, 2002.
- [Naf05] NAFE, CLEMENS: *Indexierung lokaler Daten in Peer-to-Peer-Netzwerken*. Diplomarbeit, Universität Rostock, 2005.
- [OW12] OTTMANN, THOMAS und PETER WIDMAYER: *Algorithmen und Datenstrukturen*. Spektrum Akademischer Verlag, 5 Auflage, 2012.
- [QLC14] QIAO, YAN, TAO LI und SHIGANG CHEN: *Fast Bloom Filters and their Generalization*. *Parallel and Distributed Systems, IEEE Transactions on*, 25(1):93–103, Januar 2014.
- [RK14] RUPPEL, PETER und AXEL KÜPPER: *Geocookie: A Space-Efficient Representation of Geographic Location Sets*. *Journal of Information Processing*, 22(3):418–424, 2014.
- [SAW94] SCHILIT, BILL, NORMAN ADAMS und ROY WANT: *Context-aware Computing Applications*. In: *Mobile Computing Systems and Applications, 1994. WMCSA 1994. First Workshop on*, Seiten 85–90. IEEE, 1994.
- [SBE⁺12] SARWAT, MOHAMED, JIE BAO, AHMED ELDAWY, JUSTIN LEVANDOSKI, AMR MAGDY und MOHAMED MOKBEL: *Sindbad: A Location-(B)ased Social Networking System*. In: *Proceedings of the 2012 ACM SIGMOD International Conference on Management of Data*, Seiten 649–652. ACM, 2012.
- [Sch13] SCHNELL, RAINER: *Getting Big Data But Avoiding Big Brother*. WP-GRLC, 2, 2013.
- [SS11] SAKUMA, HIROSHI und FUMIAKO SATO: *Evaluation of the Structured Bloom Filters Based on Similarity*. In: *Advanced Information Networking and Applications (AINA), 2011 IEEE International Conference on*, Seiten 316–323, März 2011.
- [STT⁺09] SHIRAKI, TORU, YUICHI TERANISHI, SUSUMU TAKEUCHI, KANAME HARUMOTO und SHOJIRO NISHIO: *A Bloom Filter-Based User Search Method Based on Movement Records for P2P Network*. In: *Applications and the Internet, 2009. SAINT '09. Ninth International Symposium on*, Seiten 177–180. IEEE, Juli 2009.
- [SW14] SCHÖNFELD, MIRCO und MARTIN WERNER: *Node Wake-(U)p via OVFS-Coded Bloom Filters in Wireless Sensor Networks*. In: *Ad Hoc Networks*, Seiten 119–134. Springer, 2014.
- [WDS15] WERNER, MARTIN, FLORIAN DORFMEISTER und MIRCO SCHÖNFELD: *AMBIENCE: A Context-Centric Online Social Network*. In: *12th IEEE Workshop on Positioning, Navigation and Communications (WPNC '15)*, 2015.
- [YL02] YANG, CONGJUN und KING-IP LIN: *An Index Structure for Improving Closest Pairs and Related Join Queries in Spatial Databases*. In: *Database Engineering and Applications Symposium, 2002. Proceedings. International*, Seiten 140–149. IEEE, 2002.

- [Zha12] ZHANG, ZHENGHAO: *Analog Bloom Filter: Efficient simultaneous query for wireless networks*. In: *Global Communications Conference (GLOBECOM), 2012 IEEE*, Seiten 3340–3346. IEEE, 2012.
- [ZJW04] ZHU, YIFENG, HONG JIANG und JUN WANG: *Hierarchical Bloom Filter Arrays (HBA): A Novel, Scalable Metadata Management System for Large Cluster-based Storage*. In: *Cluster Computing, 2004 IEEE International Conference on*, Seiten 165–174. IEEE, 2004.